

Обучение представлений в модельно-ориентированном обучении с подкреплением


Мосейчук А. Н.

Научный руководитель: Свидченко О. А.

Санкт-Петербургская школа физико-математических и компьютерных наук
НИУ ВШЭ – Санкт-Петербург

Модельно-ориентированное обучение с подкреплением


- Обучение с подкреплением — необходимо изучить такое поведение (политику) в динамической среде, чтобы максимизировать совокупное вознаграждение за свои действия.
- Модельная ориентированность — появляется модель мира, которая перенимает динамику реального мира. Эта модель на основании текущего состояния среды и некоторого действия предсказывает следующее состояние.
- Агент — сущность, которая действует в среде, и использует политику для максимизации ожидаемого вознаграждения.



Обучение представлений

- Представления – кодирование наблюдения агентом среды в некоторое векторное представление меньшей размерности.
- Качество представлений сильно влияет качество обучения агентов.
- Некоторые детали наблюдений могут быть значимыми для принятия решения, а некоторые не имеют никакого отношения к выполняемой агентом задаче.

Как выделять релевантные задаче признаки из наблюдений, и учитывать их в векторных представлениях, игнорируя остальные?




Существующие решения: реконструкция

Идея: восстанавливаем исходное изображение

Недостатки:

- Учитываются ненужные детали
- Теряются важные детали малого размера
- Не используется информация о задаче




Danijar Hafner et al., Learning latent dynamics for planning from pixels, 2019

Alex X. Lee et al., Stochastic latent actor-critic: Deep reinforcement learning with a latent variable model, 2020

Существующие решения: контрастное обучение

Идея: похожие наблюдения должны иметь близкие векторные представления, а векторные представления несхожих наблюдений должны лежать далеко друг от друга.

Недостатки: визуально разные наблюдения могут быть одинаковыми с точки зрения задачи.



Fei Deng et al., Dreamerpro: Reconstruction-free model-based reinforcement learning with prototypical representations, 2022

Masashi Okada, Tadahiro Taniguchi, DreamingV2: Reinforcement learning with discrete world models without reconstruction, 2022

Существующие решения: бисимуляция

$$\text{Bisim}(s_i, s_j) = |r_i^\pi - r_j^\pi| + \gamma \mathcal{D}(\mathcal{P}^\pi(\cdot | s_i), \mathcal{P}^\pi(\cdot | s_j))$$

r – награда, s – состояние, π – политика

$\mathcal{D}$ – расстояние, $\mathcal{P}$ – распределение

Идея: сгруппировать состояния с точки зрения “поведенческой эквивалентности”.

Преимущества: естественно используется информация о задаче.

Недостатки: не используются влияние действия на состояние, что тоже может быть релевантной решению задачи информацией.

Pablo Samuel Castro, Scalable methods for computing state similarity in deterministic Markov Decision Processes, 2019
Amy Zhang et al., Learning invariant representations for reinforcement learning without reconstruction, 2021

Цели и задачи работы

Цель: взяв за основу метрику бисимуляции и модельно-ориентированный алгоритм Dreamer V3 улучшить представление наблюдений.

Задачи:

1. Создать зашумленное окружение
2. Модифицировать метрику бисимуляции для использования ее с категориальными распределениями
3. Модифицировать метрику бисимуляции, добавив в нее информацию о действии
4. Провести тестирование для оценки качества новой метрики и сравнить ее с существующими подходами

Создание зашумленного окружения

Способы замены частей наблюдения, не относящихся к решению задачи:

1. Замена на случайно выбранное видео из некоторого набора данных (kinetics-400)
2. Замена на случайный шум из гауссовского распределения



Бисимуляция с категориальным распределением

$$\text{Bisim}(s_i, s_j) = |r_i^\pi - r_j^\pi| + \gamma \mathcal{D}(\mathcal{P}^\pi(\cdot | s_i), \mathcal{P}^\pi(\cdot | s_j))$$

r – награда, s – состояние, π – политика

$\mathcal{D}$ – расстояние, $\mathcal{P}$ – распределение

Использование в текущих работах: $\mathcal{D} = W_2(\mathcal{N}(\mu_1, \Sigma_1), \mathcal{N}(\mu_2, \Sigma_2)) = \sqrt{\|\mu_1 - \mu_2\|_2^2 + \|\Sigma_1^{1/2} - \Sigma_2^{1/2}\|_{\mathcal{F}}^2}$

Адаптация для категориальных распределений в DreamerV3:

$$\mathcal{D} = \text{JSD}(P, Q) = \frac{1}{2} D_{KL}(P \parallel M) + \frac{1}{2} D_{KL}(Q \parallel M)$$

$$M = \frac{1}{2}(P + Q)$$

D_{KL} – дивергенция Кульбака — Лейблера

Включение действий в бисимуляцию


$$\text{act-Bisim}(f(a_i, z_i), f(a_j, z_j)) = |r_{a_i, z_i} - r_{a_j, z_j}| + \gamma \mathbb{E}_a [\rho(f(a, z'_i), f(a, z'_j))]$$

$$f : A \times Z \rightarrow Z$$


z – скрытое представление, a – действие, r – награда

Идея: похожие состояния на произвольные действия реагируют похоже


Результаты: Walker Walk



Результаты: Reacher (easy)



Результаты: Reacher (hard)



Результаты: оценка на 150 играх

methods \ backgrounds	Original	Video	Noise
Walker Walk			
DreamerV3	951.8 $\pm$ 4.0	155.3 $\pm$ 4.0	645.6 $\pm$ 10.0
Bisimulation (normal)	944.8 $\pm$ 5.0	306.2 $\pm$ 8.0	355.2 $\pm$ 11.0
Bisimulation (categorical)	905.0 $\pm$ 8.0	518.8 $\pm$ 10.0	635.4 $\pm$ 11.0
Ours	846.8 $\pm$ 8.0	554.5 $\pm$ 11.0	551.8 $\pm$ 28.1
Reacher Reach Easy			
DreamerV3	886.9 $\pm$ 35.0	90.5 $\pm$ 23.0	876.1 $\pm$ 39.0
Bisimulation (normal)	568.1 $\pm$ 53.0	90.3 $\pm$ 21.0	273.3 $\pm$ 63.0
Bisimulation (categorical)	903.7 $\pm$ 16.0	583.3 $\pm$ 46.0	357.9 $\pm$ 63.0
Ours	177.1 $\pm$ 30.0	324.5 $\pm$ 57.0	241.8 $\pm$ 51.0
Reacher Reach Hard			
DreamerV3	696.4 $\pm$ 58.0	9.9 $\pm$ 4.0	32.2 $\pm$ 19.0
Bisimulation (normal)	901.9 $\pm$ 17.0	8.3 $\pm$ 3.0	13.0 $\pm$ 4.0
Bisimulation (categorical)	363.0 $\pm$ 56.0	8.4 $\pm$ 4.0	15.1 $\pm$ 3.0
Ours	801.8 $\pm$ 30.0	16.2 $\pm$ 3.0	12.7 $\pm$ 5.0

Результаты:

- Реализовано зашумленное окружение с разными типами шума
 - реализовано зашумление окружения с помощью видео
 - реализовано зашумление окружения гауссовским шумом
- Метрика бисимуляции была модифицирована для применения ее к категориальному распределению
 - проведен анализ расстояний между распределениями для использования их в метрике бисимуляции
- Была разработана модификация метрика бисимуляции с учетом действий
 - проведены эксперименты с разными подходами по включению действий в метрику бисимуляции
- Было проведено сравнение модификации метрики бисимуляции с существующими подходами
- Разработанный подход показал свое преимущество в окружениях с коррелированным шумом
 - Бисимуляция с учетом действий: победа в 2 окружениях из 3