

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»
*Факультет Санкт-Петербургская школа физико-математических и
компьютерных наук*

Мосейчук Артемий Николаевич

Обучение представлений в модельно-ориентированном обучении с подкреплением

Выпускная квалификационная работа
по направлению подготовки 01.04.02 Прикладная математика и
информатика
образовательная программа «Машинное обучение и анализ данных»

Рецензент:
магистр ПМИ, постдок, Технион

И.И. Иванов

Научный руководитель:
д. ф.-м. н., профессор

А.М. Кривцов

Консультант:
аспирант, НИУ ВШЭ СПб

О.А. Свидченко

Санкт-Петербург 2024

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	6
1. ОБЗОР ЛИТЕРАТУРНЫХ ИСТОЧНИКОВ	9
1.1. DreamerV3	9
1.2. Обучение скрытых представлений	11
1.2.1. Реконструкция	11
1.2.2. Контрастное обучение	12
1.2.3. Бисимуляция	13
1.3. Выводы и результаты по главе	14
2. ОСНОВНЫЕ КОНЦЕПЦИИ И ПОСТАНОВКА ЗАДАЧИ	15
2.1. Основные определения и концепции	15
2.2. Постановка задач	16
2.3. Выводы и результаты по главе	17
3. ОПИСАНИЕ РЕШЕНИЙ ПОСТАВЛЕННЫХ ЗАДАЧ	18
3.1. Адаптация метрики бисимуляции к категориальному распределению . .	18
3.2. Включение действий в метрику бисимуляции	18
3.3. Создание зашумленного окружения	19
3.4. Выводы и результаты по главе	20
4. ОПИСАНИЕ ИСПОЛЬЗУЕМЫХ ОКРУЖЕНИЙ И РЕЗУЛЬТАТЫ ЭКСПЕРИМЕНТОВ	22
4.1. Описание используемых окружений	22
4.1.1. Walker	22
4.1.2. Reacher	23
4.2. Результаты экспериментов	23
4.2.1. Walker Walk	25
4.2.2. Reacher Reach Easy	26
4.2.3. Reacher Reach Hard	27
4.3. Выводы и результаты по главе	28
ЗАКЛЮЧЕНИЕ	29
СПИСОК ЛИТЕРАТУРЫ	31
Монографии	31
Периодические издания	31

Аннотация

Данная работа посвящена разработке функции потерь, учитывающей информацию о задаче, с целью получения информативных представлений в модельно-ориентированном обучении с подкреплением. Обучение с подкреплением представляет собой область машинного обучения, в которой агент обучается взаимодействовать с окружающей средой через выполнение действий и получение обратной связи в виде вознаграждений или наказаний. Этот подход активно используется в различных областях, таких как робототехника, автономные транспортные средства и управление ресурсами, благодаря своей способности справляться с комплексными и динамическими средами. Важной составляющей эффективного модельно-ориентированного обучения с подкреплением являются качественные представления, которые должны быть информативными и исключать избыточную информацию. Целью данной работы является улучшение представления наблюдений в модельно-ориентированном алгоритме DreamerV3 через модификацию функции потерь на основе бисимуляции.

Annotation

This work is devoted to the development of a loss function that takes into account information about the task in order to obtain informative representations in model-based reinforcement learning. Reinforcement learning is a field of machine learning in which an agent learns to interact with its environment by performing actions and receiving feedback in the form of rewards or punishments. This approach is actively used in various fields such as robotics, autonomous vehicles and resource management due to its ability to cope with complex and dynamic environments. An important component of effective model-based reinforcement learning is high-quality representations, which must be informative and eliminate redundant information. The goal of this work is to improve the representation of observations in the model-based algorithm DreamerV3 through a modification of the loss function based on bisimulation.

Список ключевых слов

Обучение с подкреплением, модельно-ориентированное обучение с подкреплением, Dreamer, обучение представлений, информативные представления, бисимуляция.

ВВЕДЕНИЕ

Обучение с подкреплением является методом машинного обучения, при котором интеллектуальный агент (носитель некоторого поведения, политики) взаимодействует с окружающей средой методом проб и ошибок, и выучивает оптимальную стратегию поведения на основе сигналов вознаграждения, полученных в результате предыдущих взаимодействий. Одним из наиболее плодотворных аспектов обучения с подкреплением является его применимость к разным научным и инженерным областям.

Важность обучения с подкреплением трудно переоценить, поскольку его применение охватывает широкий спектр задач, требующих адаптивного принятия решений. Обучение с подкреплением активно используется в таких областях, как робототехника, управление ресурсами, игры, автономные транспортные средства и персонализированные рекомендации. Благодаря своей способности справляться с комплексными и динамическими средами, обучение с подкреплением предлагает подходы, которые могут превосходить традиционные методы, особенно в ситуациях, где требуется долгосрочное планирование и адаптация к изменениям в среде.

В обучении с подкреплением используются различные алгоритмы и подходы к решению задач, и их можно разделить на две большие категории:

- Обучение с подкреплением на основе модели мира: включает построение модели среды, которая позволяет агенту прогнозировать результаты своих действий и планировать на основе этих прогнозов. Агент, используя эту модель, может проводить симуляции для выбора оптимальных действий без необходимости многократного взаимодействия с реальной средой. Это особенно полезно в ситуациях, где взаимодействие с реальной средой дорогостоящее или рискованное.
- Безмодельное обучение с подкреплением: не полагается на явную модель среды. Вместо этого агент учится непосредственно на основе полученного опыта, присваивая ценности состояниям и действиям (Sutton & Barto, 2018). Такие алгоритмы часто проще в реализации, но могут требовать большее количество взаимодействий с реальной средой для достижения оптимального поведения.

Обучение с подкреплением на основе модели мира обладает рядом преимуществ по сравнению с безмодельными подходами:

1. Наличие модели позволяет агенту использовать планирование для прогнозирования будущих состояний и вознаграждений, что делает процесс обучения более эффективным. Агент может проигрывать различные модельные сценарии взаимодействий со средой для выбора оптимальных действий, минимизируя количество реальных взаимодействий со средой.

2. Методы на основе модели мира могут значительно ускорить процесс обучения. Поскольку агент может проводить множество симуляций внутри своей модели, он может быстро находить оптимальные стратегии, что особенно важно в сложных или дорогостоящих для обучения средах.
3. Обучение с подкреплением на основе модели мира предлагает большую гибкость и адаптивность. Агент может обновлять свою модель на основе новых данных, что позволяет ему адаптироваться к изменениям в среде и улучшать свои стратегии без необходимости полного переобучения.

Ключевым аспектом эффективности обучения с подкреплением на основе модели мира является качество представлений, используемых в модели. Представления должны быть информативными и содержать релевантную информацию о задаче, исключая при этом избыточную или нерелевантную информацию. Это позволяет агенту более точно прогнозировать результаты своих действий и строить эффективные стратегии.

Информативные представления позволяют агенту лучше понимать структуру и динамику среды, что является критическим для успешного планирования и принятия решений. Использование качественных представлений может существенно уменьшить вычислительные затраты и ускорить процесс обучения, так как агенту не нужно обрабатывать лишнюю информацию. С другой стороны, нерелевантные или избыточные данные могут усложнить модель, увеличив вычислительную сложность и потребности в памяти. Более того, это может привести к ошибкам в прогнозах и, как следствие, к неэффективным стратегиям. Поэтому разработка и использование эффективных представлений является одной из ключевых задач в обучении с подкреплением на основе модели мира.

Одним из передовых методов в области модельно-ориентированного обучения с подкреплением является алгоритм DreamerV3 (Hafner и др., 2023). DreamerV3 использует прогнозирование будущих состояний среды и действий агента на основе текущей модели мира, что позволяет агенту эффективно обучаться и планировать свои действия. Одной из ключевых особенностей DreamerV3 является использование категориальных распределений для представления вероятностных характеристик будущих состояний и вознаграждений. Это позволяет более точно моделировать неопределенности и вариативности среды, что улучшает качество планирования и принятия решений. Еще такие распределения облегчают вычисление градиентов, что ускоряет процесс обучения и делает его более стабильным (Bengio и др., 2013).

Для получения информативных представлений, учитывающих информацию о задаче, необходимо научиться сравнивать частично наблюдаемые марковские процессы принятия решений. Одним из способов это сделать является метрика бисимуляции (Ferns и др., 2011). Метрика бисимуляции является важным инструментом для

оценки сходства состояний в модельно-ориентированном обучении с подкреплением. Она учитывает информацию о задаче, сравнивая состояния на основе их воздействия на будущее поведение агента и получаемое вознаграждение. Однако, традиционная метрика бисимуляции не учитывает действия агента, что может ограничивать ее способность формировать информативные представления. В реальных задачах, где действия играют ключевую роль в достижении целей, это может привести к потере важной информации и, как следствие, к менее эффективному обучению.

Данная работа посвящена разработке функции потерь, учитывающую информацию о задаче, с целью получения информативных представлений в модельно-ориентированном обучении с подкреплением. Проверка разработанной функции потерь проводится на алгоритме DreamerV3.

Целью данной работы является улучшение представления наблюдений в модельно-ориентированном алгоритме DreamerV3 через модификацию метрики бисимуляции. Для достижения данной цели были определены следующие задачи:

1. создать разные варианты зашумленных окружений;
2. модифицировать метрику бисимуляции для возможности использования ее с категориальными распределениями;
3. модифицировать метрику бисимуляции, добавив в нее информацию о действии;
4. провести тестирование для оценки качества новых метрик и сравнить ее с существующими подходами.

Работа структурирована следующим образом: Глава 1 посвящена подробному описанию алгоритма DreamerV3 и обзору источников по существующим подходам обучения представлений. Глава 2 содержит основные понятия и определения, а также подробную постановку задач работы. В Главе 3 содержится описание решений поставленных задач. В Главе 4 представлены описание окружений, на которых проводятся эксперименты и результаты тестирования модификаций функций потерь на этих окружениях с разными вариантами шума.

1. ОБЗОР ЛИТЕРАТУРНЫХ ИСТОЧНИКОВ

Данная глава посвящена обзору алгоритма DreamerV3 и существующим методам обучения представлений.

1.1. DreamerV3

DreamerV3 представляет собой одну из самых продвинутых реализаций алгоритмов обучения с подкреплением в контексте модельно-ориентированных подходов. Этот алгоритм является улучшением предшествующих алгоритмов Dreamer и DreamerV2, и включает в себя улучшения, направленные на повышение эффективности обучения агентов в сложных средах. DreamerV3 продемонстрировал высокую производительность в различных областях, изучая мощные модели мира в скрытом пространстве с использованием функции потерь реконструкции пикселей.

Алгоритм DreamerV3 (Hafner и др., 2023) состоит из трех нейронных сетей: модель мира предсказывает результаты потенциальных действий, критик оценивает ценность каждого результата, а актор выбирает действия, максимизирующие значения функции ценности. Компоненты обучаются одновременно на основе воспроизведенного опыта, пока агент взаимодействует со средой.

Модель мира в DreamerV3 строит внутреннюю модель среды, которая предсказывает будущее состояние и соответствующие вознаграждения на основе текущего состояния и действий агента. Модель мира выучивает компактные представления сигналов, полученных из сенсорных систем, используя автоэнкодер и позволяет планировать поведение через предсказание будущих представлений и наград для потенциальных действий.

Модель мира представляется как Recurrent State-Space Model (RSSM). Сперва автоэнкодер отображает сигналы сенсорных систем x_t в стохастическое представление z_t . Затем модель последовательности с рекуррентным состоянием h_t предсказывает последовательность представлений по предшествующему действию a_{t-1} . Конкатенация h_t и z_t формирует состояние модели для предсказания награды r_t и флага продолжения эпизода $c_t \in \{0, 1\}$.

Математическое описание DreamerV3:

Модель последовательности:	$h_t = f_\phi(h_{t-1}, z_{t-1}, a_{t-1})$
Кодировщик:	$z_t \sim q_\phi(z_t \mid h_t, x_t)$
Предиктор динамики:	$\hat{z}_t \sim p_\phi(\hat{z}_t \mid h_t)$
Предиктор награды:	$\hat{r}_t \sim p_\phi(\hat{r}_t \mid h_t, z_t)$
Предиктор продолжения эпизода:	$\hat{c}_t \sim p_\phi(\hat{c}_t \mid h_t, z_t)$
Декодировщик:	$\hat{x}_t \sim p_\phi(\hat{x}_t \mid h_t, z_t)$

Кодировщик и декодировщик использует сверточные сети для входных данных

в виде изображений и многослойный перцептрон для векторного входа. Предикторы динамики, награды и продолжения состояния представляют собой также многослойный перцептрон. Представления отбираются из вектора softmax-распределений. Параметры модели мира ϕ оптимизируются по данной последовательности входов $x_{1:T}$, действий $a_{1:T}$, наград $r_{1:T}$ и флагов продолжения эпизода $c_{1:T}$ путем минимизации функций потерь по предиктору награды, предиктору продолжения эпизода и декодировщику $\mathcal{L}_{\text{pred}}$, по предиктору динамики $\mathcal{L}_{\text{dyn}}$, и по кодировщику $\mathcal{L}_{\text{rep}}$ с соответствующими им весами:

$$\begin{aligned}\mathcal{L}(\phi) &= \mathbb{E}_{q_\phi} \left[\sum_{t=1}^T (\beta_{\text{pred}} \mathcal{L}_{\text{pred}}(\phi) + \beta_{\text{dyn}} \mathcal{L}_{\text{dyn}}(\phi) + \beta_{\text{rep}} \mathcal{L}_{\text{rep}}(\phi)) \right] \\ \mathcal{L}_{\text{pred}}(\phi) &= -\ln p_\phi(x_t | z_t, h_t) - \ln p_\phi(r_t | z_t, h_t) - \ln p_\phi(c_t | z_t, h_t) \\ \mathcal{L}_{\text{dyn}}(\phi) &= \max(1, \text{KL}[sg(q_\phi(z_t | h_t, x_t)) || p_\phi(z_t | h_t)]) \\ \mathcal{L}_{\text{rep}}(\phi) &= \max(1, \text{KL}[q_\phi(z_t | h_t, x_t) || sg(p_\phi(z_t | h_t))])\end{aligned}$$

где sg – оператор остановки градиента.

Нейронные сети актора ($a_t \sim \pi_\theta(a_t | s_t)$) и критика ($v_\phi(R_t | s_t)$) изучают поведение непосредственно из траекторий скрытых представлений, получаемых из сети модели мира. Актор и критик взаимодействуют с пространством состояний модели мира $s_t = h_t, z_t$ используя марковские представления, изучаемые рекуррентной моделью мира. Задача актора заключается в максимизации кумулятивной награды $R_t = \sum_{\tau=0}^{\infty} \gamma^\tau r_{t+\tau}$, где γ является множителем дисконтирования. Для прогнозирования кумулятивных наград за пределами горизонта планирования, критик оценивает распределение кумулятивных наград для каждого состояния на основе текущего поведения актора.

Начиная с представлений воспроизведенных входных данных, модель мира и актор генерируют траекторию воображаемых состояний модели $s_{1:T}$, действий $a_{1:T}$, вознаграждений $r_{1:T}$ и флагов продолжения эпизода $c_{1:T}$. Так как критик предсказывает распределения, то его прогнозируемые значения считаются как математическое ожидание распределения $v_t = \mathbb{E}[v_\psi(\cdot | s_t)]$. Для расчета кумулятивной награды за пределами горизонта планирования рассчитываются бутстрэпированные кумулятивные награды (Sutton & Barto, 2018), которые объединяют предсказываемые кумулятивные награды и значения функции ценности. Критик учится предсказывать распределения оценок кумулятивных наград R_t^λ используя функцию потерь оценки максимального правдоподобия:

$$\mathcal{L}(\psi) = - \sum_{t=1}^T \ln p_\psi(R_t^\lambda | s_t), \quad R_t^\lambda = r_t + \gamma c_t ((1 - \lambda)v_t + \lambda R_{t+1}^\lambda), \quad R_T^\lambda = v_T$$

Актор учится выбирать действие, максимизирующее кумулятивную награду, исследуя окружение с помощью регуляризатора энтропии.

$$\mathcal{L}(\theta) = - \sum_{t=1}^T sg \left((R_t^\lambda - v_\psi(s_t)) / \max(1, S) \right) \log \pi_\theta(a_t \mid s_t) + \eta H[\pi_\theta(a_t \mid s_t)]$$

$$S = \text{EMA} \left(\text{Per}(R_t^\lambda, 95) - \text{Per}(R_t^\lambda, 5), 0.99 \right)$$

Скрытое представление z_t может быть представлено параметрами гауссовского распределения μ_t, Σ_t , но основным является представление в виде категориального распределения, так как такое представление, по доводам авторов, является более выразительным (Hafner и др., 2020).

1.2. Обучение скрытых представлений

1.2.1. Реконструкция

Реконструкционная функция потерь является метрикой, используемой для оценки качества восстановления исходных данных из их представлений в скрытом пространстве. В типичном сценарии автоэнкодера, модель обучается минимизировать разницу между входными данными и их реконструкцией, генерируемой моделью-декодером. Эта разница и есть реконструкционная потеря. Формально, если x представляет собой входные данные, $\hat{x}$ — реконструированные данные, то ошибка реконструкции выражается как

$$-\mathbb{E}_{z \sim q_\phi(z \mid x)} [\log p_\theta(x \mid z)]$$

где $q_\phi(z \mid x)$ — вероятностный кодировщик, $p_\theta(x \mid z)$ — вероятностный декодировщик.

Ранние работы по глубокому обучению с подкреплением с использованием изображений (Lange и др., 2012) использовали двухэтапный процесс обучения, в котором сначала автокодировщик обучался с реконструкционной функцией потерь для изучения скрытых представлений в некотором пространстве низкой размерности, а затем агент изучал политику с использованием этих скрытых представлений. Это позволяло эффективно использовать большие неразмеченные наборы данных для изучения скрытых представлений и дальнейшего использования в обучении агента. Но на практике нет никакой гарантии, что изученное скрытое представление будет содержать полезную для изучения политики информацию.

Для того чтобы эти подходы работали, часто необходимы экспертные знания и приемы. В обучении с подкреплением на основе модели мира одним из решений этой проблемы было совместное сквозное обучение модели кодировщика и модели динамики (Wahlström и др., 2015) — это оказалось эффективным при изучении скрытых представлений, ориентированных на задачу. Другие авторы Hafner и др., 2019; Lee и

др., 2020 изучают модели, отображающие входные данные в латентное пространство, с использованием потерь при реконструкции, но этот подход испытывает сложности в получении точных предсказаний на длинном горизонте, и часто все еще требуют значительной ручной настройки.

1.2.2. Контрастное обучение

Цель контрастного обучения – изучить такое пространство скрытых представлений, в котором визуально похожие пары наблюдений остаются близко друг к другу, а различные – далеко друг от друга.

Классическая формулировка контрастной функции потерь выглядит так (Chopra и др., 2005): пусть дан набор входных данных $\{x_i\}$, каждый элемент которого имеет соответствующую метку $y_i \in \{1, \dots, L\}$ из возможных L классов. Тогда цель – получить функцию $f_\theta(\cdot) : X \rightarrow Z$, что переводит x_i в некоторый элемент z пространства Z , такой, что любой другой элемент, с такой же меткой, имеет близкий к z вектор z' , а любой другой элемент с другой меткой имеет сильно отличающийся от z вектор z' . Таким образом контрастная функция потерь для каждой пары (x_i, x_j) минимизирует расстояние между их скрытыми представлениями для объектов одного класса, и максимизирует для объектов разных классов:

$$\mathcal{L}(x_i, x_j, \theta) = \mathbb{1}[y_i = y_j] \|f_\theta(x_i) - f_\theta(x_j)\|_2^2 + \mathbb{1}[y_i \neq y_j] \max(0, \epsilon - \|f_\theta(x_i) - f_\theta(x_j)\|_2)^2$$

где ϵ – гиперпараметр, определяющий нижнюю границу расстояния между объектами с различными классами.

Контрастное обучение представляет собой самоконтролируемый подход для получения полезных векторных представлений путем введения ограничений на сходство между данными (Chen и др., 2020). В этом подходе функции сходства играют ключевую роль. Они могут быть основаны на знаниях о предметной области и реализованы через эвристическое обогащение данных. Например, сходство между различными аугментациями одного и того же объекта данных или соседними фрагментами изображений максимизируется, а сходство между различными объектами данных минимизируется.

Существуют различные модификации алгоритмов семейства DREAMER с использованием контрастного обучения, но многие из них работают с непрерывными скрытыми представлениями (Deng и др., 2022), и не используют преимуществ в выразительности категориальных распределений. Подход с адаптацией контрастного обучения к категориальным представлениям наблюдений был предложен в работе Okada и Taniguchi, 2022 и показал свое преимущество перед методами контрастного обучения с использованием непрерывных представлений наблюдений.

Но подход на основе контрастного обучения и обучения на основе реконструкции

имеют большие недостатки:

1. они имеют особенность терять детали наблюдений, которые могут оказаться важными с точки зрения задачи;
2. они никак не учитывают какую-либо информацию о задаче.

Более эффективным методом было бы включение информации о задаче в функцию сходства. Это позволит группировать изображения, которые сильно различаются по пиксельной структуре (например, из-за изменений освещения или текстуры), как схожие с точки зрения задачи.

1.2.3. Бисимуляция

Марковский процесс принятия решения является распространенным способом кодирования процесса принятия решения в задачах обучения с подкреплением (Sutton & Barto, 2018). Марковский процесс принятия решения считается решенным, когда найдена политика (поведение для каждого состояния), которая максимизирует кумулятивную награду (García и др., 2022). Бисимуляция и метрика бисимуляции работает с марковскими процессами принятия решений.

Абстракция состояний – процесс группировки состояний в абстрактные представления, более компактные и удобные в работе, но сохраняющие динамику исходной системы. Более формально: пусть S – пространство состояний, назовем *абстракцией состояний* отображение $\phi : S \rightarrow Z$ пространства S в некоторое конечное абстрактное пространство Z .

В Марковских процессах принятия решений определены различные формы абстракции состояний для группировки состояний в кластеры, которые сохраняют некоторое свойство (оптимальную ценность или все ценности, или все ценности действий из каждого состояния). Строгая форма абстракции состояний, сохраняющая большинство свойств – бисимуляция. Только бисимуляция группирует состояния, которые являются неотличимыми по последовательности наград для любой последовательности действий. Связанной концепцией является метрика бисимуляции (Ferns & Precup, 2014), которая измеряет насколько одно состояние является поведенчески эквивалентно другому. Ferns и др., 2011 определяют метрику бисимуляции для непрерывных марковских процессов принятия решения и предлагают алгоритм Монте-Карло для обучения распределений перехода и последующим подсчетом расстояния Вассерштейна между ними. Однако этот метод плохо масштабируется на больших пространствах состояний.

Taylor и др., 2008 связывают гомоморфизмы марковских процессов принятия решений со слабой вероятностной бисимуляцией, и определяют метрику слабой бисимуляции, которая агрегирует приблизительно эквивалентные пары состояние-действие.

Затем они доказывают, что разница оптимальных значений функции ценности различных состояний могут быть ограничены сверху значением этой метрики, и эта граница является более строгой чем у бисимуляции.

Castro, 2020 предложил алгоритм вычисления метрик бисимуляции на основе политики, но он делает это напрямую, без изучения представлений. Они сосредоточены на детерминистских условиях и проблеме оценки политики.

Zhang и др., 2020 предложили градиентный метод обучения скрытых представлений с помощью метрики бисимуляции, и показали, что он работает в условиях оптимизации политики. Метод показал свое превосходство над подходом с реконструкцией и контрастным обучением на окружениях с зашумлением видео.

1.3. Выводы и результаты по главе

В данной главе было дано описание алгоритма DreamerV3 и были рассмотрены различные подходы к обучению представлений. Такие подходы, как контрастное обучение и обучение с помощью реконструкции, неспособны создавать информативные с точки зрения задачи скрытые представления наблюдений. Эту проблему решает подход на основе бисимуляции, но ее применение к алгоритму DreamerV3 требует адаптации. К тому же у этой метрики можно выделить некоторые идейные недостатки.

В следующей главе будет дан необходимый для работы теоретический контекст. Будет проанализирован подход к обучению скрытых представлений на основе бисимуляции, на основе этого анализа будут сформулированы задачи работы.

2. ОСНОВНЫЕ КОНЦЕПЦИИ И ПОСТАНОВКА ЗАДАЧИ

2.1. Основные определения и концепции

Марковский процесс принятия решений формально определяется набором

$$(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma)$$

где $\mathcal{S}$ – множество состояний s , $\mathcal{A}$ – множество действий a , $\mathcal{P}(s' \mid s, a)$ – вероятность перехода из состояния $s \in \mathcal{S}$ в состояние $s' \in \mathcal{S}$, $\gamma \in [0, 1)$ является фактором дисконтирования. Состояние системы s переходит в состояние $s' \sim \mathcal{P}(s, a)$ при выполнении агентом действия $a \in \mathcal{A}$, соответствующего политике $a \sim \pi(s)$, и за которое агент получает награду $r = \mathcal{R}(s) \in \mathbb{R}$. Цель агента заключается в максимизации математического ожидания кумулятивной дисконтированной награды путем изучения хорошей политики: $\max_{\pi} \mathbb{E} \left[\sum_{t=0}^{\infty} [\gamma^t \mathcal{R}(s_t)] \right]$

В работе рассматривается обучение на основе наблюдений, где наблюдения представлены изображениями, и можно было бы явно отличать пространство наблюдений $\mathcal{O}$ от пространства состояний $\mathcal{S}$. Но, так как в данной работе не решается общая проблема частично наблюдаемых марковских процессов, то будет рассматриваться блочный марковский процесс принятия решений (Du и др., 2019), который предполагает что пространство состояний $\mathcal{S}$ неизвестно, а вместо этого есть доступ к пространству наблюдений $\mathcal{O}$ и функции рендеринга $q : \mathcal{S} \rightarrow \mathcal{O}$. Основное допущение (Du и др., 2019) следующее: каждое наблюдение o однозначно определяется его порождающим состоянием s . То есть, пространство наблюдений $\mathcal{O}$ может быть разбито на дизъюнктные множества $\mathcal{O}_s$, каждое из которых содержит носителя условного распределения $q(o \mid s)$. Это предположение дает нам марковское свойство в пространстве наблюдений $\mathcal{O}$.

Отношение стохастической бисимуляции представляет собой отношение эквивалентности на марковских процессах принятия решений, что разбивает пространство состояний на непересекающиеся множества, точки которых эквивалентны по данному отношению. Два состояния s и s' поведенчески эквивалентны (биподобны) если для каждого из них получаемая награда одинакова и распределения следующих биподобных состояний совпадают. Формально:

$$s \sim_B s' \iff \forall a : R(s, a) = R(s', a) \wedge \forall x \in \mathcal{S} / \sim_B : \mathcal{P}(x \mid s, a) = \mathcal{P}(x \mid s', a)$$

Метрика бисимуляции смягчает строгое отношение бисимуляции, делая его более пригодным для зашумленных наблюдений.

Метрика бисимуляции (Ferns и др., 2011) для непрерывных марковских процес-

сов принятия решения: пусть $\mathcal{R} : \mathcal{S} \times \mathcal{A} \rightarrow [0, 1]$ и $c \in (0, 1)$, (M, d) – метрическое пространство, для которого любая вероятностная мера на M является мерой Радона, тогда метрика бисимуляции определяется как

$$d(s_i, s_j) = \max_{a \in \mathcal{A}} |\mathcal{R}(s_i, a) - \mathcal{R}(s_j, a)| + c\mathcal{W}_1(d)(\mathcal{P}(\cdot \mid s_i, a), \mathcal{P}(\cdot \mid s_j, a)) \quad (1)$$

Где $\mathcal{W}_1(d)$ – 1-я метрика Вассерштейна.

Метрика бисимуляции, основанная на политике (Castro, 2020): пусть дана фиксированная политика π , тогда следующая метрика бисимуляции существует и единственна

$$d_\pi(s_i, s_j) = |r_i^\pi - r_j^\pi| + \gamma\mathcal{W}_1(d_\pi)(\mathcal{P}^\pi(\cdot \mid s_i), (\mathcal{P}^\pi(\cdot \mid s_j)))$$

Из этой метрики Zhang и др., 2020 была выведена функция потерь для обучения представлений, ориентированных на задачу:

$$\mathcal{J}(\phi) = \left(\|z_i - z_j\|_1 - |r_i - r_j| - \gamma\mathcal{W}_2(\hat{\mathcal{P}}(\cdot \mid sg(z_i), a_i), \hat{\mathcal{P}}(\cdot \mid sg(z_j), a_j)) \right)^2 \quad (2)$$

где $\phi : \mathcal{S} \rightarrow \mathcal{Z}$, $\mathcal{Z}$ – пространство скрытых представлений; $z_i = \phi(s_i)$, $z_j = \phi(s_j)$; r – награды; sg – оператор остановки градиентов; $\mathcal{P}$ – вероятностная модель динамики, выход которой предоставляет параметры гауссовского распределения.

В этой функции потерь $\mathcal{W}_1$ заменена на $\mathcal{W}_2$ по сравнению с оригинальной метрикой бисимуляции. $\mathcal{W}_2$ для Гауссовских распределений имеет следующую форму:

$$\mathcal{W}_2(\mathcal{N}(\mu_i, \Sigma_i), \mathcal{N}(\mu_j, \Sigma_j))^2 = \|\mu_i - \mu_j\|_2^2 + \|\Sigma_i^{1/2} - \Sigma_j^{1/2}\|_{\mathcal{F}}^2 \quad (3)$$

где $\|\cdot\|_{\mathcal{F}}$ – норма Фробениуса.

2.2. Постановка задач

Метрика бисимуляции (1) измеряет, насколько схожи два состояния с точки зрения возможных наград и переходов между ними, таким образом учитывая информацию о задаче. В классических формулировках метрики бисимуляции используется расстояние Вассерштейна, хорошо подходящее для непрерывных распределений, таких как гауссовские (3). Однако в современных моделях обучения с подкреплением, таких как DreamerV3, для кодирования наблюдений часто применяются категориальные распределения. Использование расстояния Вассерштейна для этих распределений затруднительно из-за отсутствия подходящей метрики в пространстве категориальных распределений и сложности вычислений. Поэтому возникает необходимость в адаптации метрики бисимуляции для категориальных распределений, что требует введения альтернативной меры расстояния между распределениями.

Задача 1: Адаптировать функцию потерь бисимуляции (2) для использования ее

с категориальными распределениями в DreamerV3 путём замены расстояния Вассерштейна на альтернативную меру.

Но функция потерь бисимуляции (2) не учитывает действия, что может повлиять на качество и информативность представлений. Включение действий обеспечивает то, что представления учитывают, как различные действия влияют на состояния. Это повышает специфичность представлений, делая их более дифференцированы и информативными для принятия решений. Например, два состояния, которые визуально могут выглядеть похоже, и будут иметь одинаковые награды и распределения следующих состояний с учетом политики, будут иметь отличающиеся представления, если они по-разному реагируют на одинаковые действия. Модификация функции потерь для явного учета всех возможных действий поможет создать более универсальные и информативные представления, которые лучше отражают динамику среды вне зависимости от текущей политики.

Задача 2: Модифицировать метрику бисимуляции (1) и функцию потерь бисимуляции (2) для возможности ее применения к парам $(s, a) \in \mathcal{S} \times \mathcal{A}$.

Для исследования эффективности и устойчивости получившихся адаптаций и модификаций функций потерь необходимы зашумленные окружения. Проверка на зашумленных данных позволит понять их свойства генерализации, а также то, насколько они получились устойчивыми к внешним искажениям. Также зашумленные окружения позволят создать условия, приближенные к реальному миру.

Задача 3: Создать зашумленные окружения со случайным шумом и коррелированным шумом (в виде зашумления видео).

2.3. Выводы и результаты по главе

В данной главе был приведен необходимый теоретический контекст. Также был проанализирован подход к обучению информативных представлений на основе бисимуляции, были выделены его текущие недостатки и сформулированы задачи данной работы. В следующей главе будет представлено описание решений поставленных задач.

3. ОПИСАНИЕ РЕШЕНИЙ ПОСТАВЛЕННЫХ ЗАДАЧ

3.1. Адаптация метрики бисимуляции к категориальному распределению

В качестве альтернативы расстоянию Вассерштейна, для категориальных распределений была взята дивергенция Йенсена-Шеннона, которая основывается на дивергенции Кульбака-Лейблера, и является её симметричной и сглаженной версией (Briët & Harremoës, 2009). Дивергенция Йенсена-Шеннона определяется следующим образом:

$$\begin{aligned} \text{JSD}(P \parallel Q) &= \frac{1}{2}D_{KL}(P \parallel M) + \frac{1}{2}D_{KL}(Q \parallel M) \\ M &= \frac{1}{2}(P + Q) \end{aligned}$$

Причем

$$\text{JSD}_\rho(P \parallel Q) = \sqrt{\frac{1}{2}D_{KL}(P \parallel M) + \frac{1}{2}D_{KL}(Q \parallel M)}$$

является метрикой. Это удовлетворяет теоретическим основаниям метрики бисимуляции (Ferns и др., 2011). Таким образом новая формулировка функции потерь на основе бисимуляции (2) имеет следующий вид:

$$\mathcal{J}(\phi) = \left(\|z_i - z_j\|_1 - |r_i - r_j| - \gamma \text{JSD}(\hat{\mathcal{P}}(\cdot \mid sg(z_i), a_i) \parallel \hat{\mathcal{P}}(\cdot \mid sg(z_j), a_j)) \right)^2$$

где $\phi : \mathcal{S} \rightarrow \mathcal{Z}$, $\mathcal{Z}$ – пространство скрытых представлений; $z_i = \phi(s_i)$, $z_j = \phi(s_j)$; r – награды; sg – оператор останова градиентов; $\mathcal{P}$ – вероятностная модель динамики, выход которой предоставляет матрицу категориального распределения.

3.2. Включение действий в метрику бисимуляции

Для включения действий в метрику бисимуляции и функцию потерь на основе бисимуляции (1, 2) необходимо определить метрику на парах $(s, a) \in \mathcal{S} \times \mathcal{A}$.

Определим в общем виде новую метрику на основе бисимуляции с учетом действий:

$$d_{act}((s_i, a_i), (s_j, a_j)) = |r_{s_i, a_i} - r_{s_j, a_j}| + \gamma \mathbb{E}_a [\mathcal{D}(\mathcal{P}(\cdot \mid s'_i, a), \mathcal{P}(\cdot \mid s'_j, a))]$$

где s'_i, s'_j – следующие состояния после s_i, s_j при выполнении действий a_i, a_j .

Функция потерь на основе бисимуляции с учетом действий будет выглядеть так:

$$\mathcal{J}(\phi) = \left(\|z_i - z_j\|_1 - |r_{z_i, a_i} - r_{z_j, a_j}| - \gamma \mathbb{E}_a [\mathcal{D}(\mathcal{P}(\cdot \mid sg(z'_i), a), \mathcal{P}(\cdot \mid sg(z'_j), a))] \right)^2$$

где $z_i = \phi(s_i)$, $z_j = \phi(s_j)$ – скрытые представления соответствующих состояний, sg – оператор останковки градиента.

Таким образом пары вида (s, a) считаются одинаковыми, если при выполнении действия из пары в состоянии из пары получаемая награда одинакова и распределение следующих состояний из состояния (s', a) одинаковы для любых произвольных действий. И группировка одинаковых состояний происходит именно по таким свойствам, что позволяет делать состояния более дифференцированными с точки зрения реакций на действия, вне зависимости от текущей политики.

Вместо использования вероятностной модели динамики $\mathcal{P}(\cdot | \cdot)$ можно взять отображение из $\mathcal{Z} \times \mathcal{A}$ в $\mathcal{Z}$. Пусть $f : \mathcal{Z} \times \mathcal{A} \mapsto \mathcal{Z}$ – функция, которая паре (скрытое состояние, действие) ставит в соответствие следующее скрытое состояние. Тогда можно определить метрику на основе бисимуляции с учетом действий без использования вероятностной модели динамики так:

$$d_{act}((z_i, a_i), (z_j, a_j)) = |r_{z_i, a_i} - r_{z_j, a_j}| + \gamma \mathbb{E}_a [\rho(f(z'_i, a), f(z'_j, a))]$$

где ρ – некоторая функция расстояния, которая зависит от вида z ; z'_i, z'_j – следующие скрытые представления состояний после z_i, z_j при выполнении действий a_i, a_j .

Функция потерь на основе бисимуляции с учетом действий без использования вероятностной модели динамики будет выглядеть так:

$$\mathcal{J}(\phi) = \left(\|z_i - z_j\|_1 - |r_{s_i, a_i} - r_{s_j, a_j}| - \gamma \mathbb{E}_a [\rho(sg(f(z'_i, a)), sg(f(z'_j, a)))] \right)^2 \quad (4)$$

В данном случае f представляет собой комбинацию линейных моделей ϕ_a, ϕ_z , и выражается следующим образом $f(z, a) = \phi_a(a) \odot \phi_z(z)$ ($\odot$ – произведение Адамара). Параметры данных моделей обучаются по данным из среды путем минимизации некоторой функции потерь $\mathcal{L}(\phi_a(a) \odot \phi_z(z); z')$, где z' – следующее скрытое состояние при выполнении действия a .

Идея внедрения функции f мотивирована работой Pathak и др., 2017. Эта идея заключается в том, что так как функция по текущему скрытому представлению z и действию a предсказывает следующее скрытое состояние z' , то модель, которая соответствует этой функции, будет концентрироваться на тех частях скрытого представления z , на которые влияет действие a' . И этот аспект будет дополнительно помогать получать информативные по отношению к действиям скрытые представления.

3.3. Создание зашумленного окружения

Было создано два типа шума: случайный и коррелированный. Среда для зашумления были взяты из программного пакета `dm_control` (Tunyasuvunakool и др., 2020), который представляет собой набор задач для агентов обучения с подкреплением с



(a) Случайное зашумление фона



(b) Зашумление фона видео

Рис. 1: Пример зашумления для окружения Walker Walk из dm_control

моделированием шарнирно-сочлененных тел.

Случайный шум добавляется к данным случайным образом и заменяет фоновые детали исходных изображений состояний, не имея никакой корреляции со структурой данных. Необходимый кадр со случайным шумом создается каждый раз при обновлении состояния среды.

Коррелированный шум добавляет структурированные помехи, такие как случайные видеоклипы, которые также заменяют фоновые детали исходных изображений состояний. Видеоклипы загружаются из некоторого указанного источника и преобразовываются под размер изображений наблюдений. Кадр фона меняется при обновлении состояния. При каждой новой инициализации среды загружается случайно выбранный видеоклип из набора данных.

В случае если фоновых частей несколько, то на каждую из частей накладывается отдельный вариант шума. Например, фон в рисунке 1b можно разбить на две части: дорога и заднее изображение сцены, и каждой из частей будет соответствовать свое видео, из которого будут браться кадры для этой части.

3.4. Выводы и результаты по главе

В данной главе было приведено решение поставленных в главе 2 задач. Метрика бисимуляции была адаптирована для использования с категориальным распределением, были предложены устранения недостатков метрики бисимуляции для получения более дифференцированных и информативных вне зависимости от политики представлений. Добавлены варианты зашумления окружений из программного пакета dm_control, приведены примеры зашумления. В следующей главе будут даны

описания используемых окружений для экспериментов и представлены результаты сравнения построенных функций потерь с существующими подходами.

4. ОПИСАНИЕ ИСПОЛЬЗУЕМЫХ ОКРУЖЕНИЙ И РЕЗУЛЬТАТЫ ЭКСПЕРИМЕНТОВ

4.1. Описание используемых окружений

4.1.1. Walker

Walker из `dm_control` является одним из стандартных агентов в среде для исследования и обучения с подкреплением. Walker представляет собой антропоморфного робота (двуногого агента), задача которого заключается в передвижении вперёд, имитируя человеческую ходьбу. Среда Walker включает несколько задач, каждая из которых имеет свои цели и специфические награды. Одной из задач является задача Walk. В задаче Walk агент должен научиться ходить вперёд, поддерживая равновесие и избегая падений. Начальное состояние агента обычно состоит из стояния на месте, и его цель – как можно быстрее двигаться вперёд.

Система наград в задаче walk включает несколько компонентов, которые вместе поощряют агента за успешное выполнение задачи. Награда представляет собой комбинацию условий, поощряющих вертикальное положение туловища и некоторую минимальную высоту туловища. Также включен компонент, стимулирующий скорость движения вперед.

Вектор действий включает в себя 6 компонентов на диапазоне $[-1, 1]$ соответствующих 6 суставам робота.




Рис. 2: Пример оригинального наблюдения среды Walker

4.1.2. Reacher

Reacher из `dm_control` представляет собой задачу, в которой двухзвенный робот-манипулятор должен научиться достигать определённых целей в своём рабочем пространстве. Эта задача тестирует способности агента к точному контролю и планированию движений.

В задаче Reacher агент управляет двухзвенным манипулятором с целью коснуться сферы. Начальное состояние обычно задаётся случайным образом, и целевая сфера также размещается случайно в пределах досягаемости манипулятора.

Награда поступает только тогда, когда конец руки робота проникает внутрь целевой сферы.

Вектор действий включает в себя 2 компонента на диапазоне $[-1, 1]$ соответствующих 2 суставам робота.

Существует две вариации задачи Easy и Hard. Разница между ними только в величине сферы. В задаче Easy целевая сфера больше чем в задаче Hard.



Рис. 3: Пример оригинального наблюдения среды Reacher Reach Hard

4.2. Результаты экспериментов

В данном разделе будут приведены графики обучения для трех разных окружений: Walker Walk, Reacher Reach Hard, Reacher Reach Easy. Каждое из представленных окружений было в оригинальном виде, с зашумлением видео и со случайным шумом.

Длительность каждого обучения 1 миллион шагов, время обучения агента на каждом варианте окружении ~ 2 GPU-дня. Гиперпараметры для обучения были взяты из Hafner и др., 2023.

Для зашумления видео была взята выборка из датасет Kinetics-400 (Kay и др., 2017). Отдельно были выделены видео для этапа тренировки (~ 28000), отдельно для этапа оценки (~ 10000). На каждом этапе оценки агент выполнял 16 эпизодов (игр) в среде. Эти эпизоды проводились для получения статистически значимых данных о производительности агента. Для оценки производительности агента использовались следующие метрики: среднее значение накопленных вознаграждений за 16 эпизодов; 95% доверительные интервалы, которые рассчитывались на основе стандартного отклонения с 16 эпизодов.

На графиках ниже отображены 95% доверительные интервалы. Для визуализации трендов в изменении метрик производительности применялось сглаживание с использованием скользящего среднего с окном определенного размера. Это позволило уменьшить влияние случайных колебаний и более четко отобразить тренды.

Приведенные в таблицах значения средних и доверительных интервалов считались по финальным весам на 150 эпизодах.

Функция потерь на основе бисимуляции с учетом действий использовалась без вероятностной модели динамики (4).

4.2.1. Walker Walk




Рис. 4: Результаты обучения Walker Walk

Таблица 1: Численные данные по окружению Walker Walk

Walker Walk Environment			
methods \ backgrounds	Original	Video	Noise
DreamerV3	951.8 ± 4.0	155.3 ± 4.0	645.6 ± 10.0
Bisimulation (normal)	944.8 ± 5.0	306.2 ± 8.0	355.2 ± 11.0
Bisimulation (categorical)	905.0 ± 8.0	518.8 ± 10.0	635.4 ± 11.0
Ours	846.8 ± 8.0	554.5 ± 11.0	551.8 ± 28.1

Можно заметить, что в оригинальном окружении лучше всего себя показала оригинальная имплементация DreamerV3. В зашумленном видео окружении подход на основе бисимуляции с включением действий (4) оказался лучше остальных. Интересно, что при случайном зашумлении лучше всего показал себя оригинальный подход из DreamerV3 на основе реконструкции. В этом случае декодер восстанавливал фон из скрытого представления средним значением случайного шума.

4.2.2. Reacher Reach Easy




Рис. 5: Результаты обучения Reacher Reach Easy

Таблица 2: Численные данные по окружению Reacher Reach Easy

Walker Walk Environment			
methods \ backgrounds	Original	Video	Noise
DreamerV3	886.9 ± 35.0	90.5 ± 23.0	876.1 ± 39.0
Bisimulation (normal)	568.1 ± 53.0	90.3 ± 21.0	273.3 ± 63.0
Bisimulation (categorical)	903.7 ± 16.0	583.3 ± 46.0	357.9 ± 63.0
Ours	177.1 ± 30.0	324.5 ± 57.0	241.8 ± 51.0

В данном случае в незашумленном окружении лучше всего себя показали адаптированная к категориальному распределению бисимуляция и имплементация DreamerV3. В зашумлении видео подход с адаптацией к категориальному распределению также показал лучшие результаты. На случайном шуме оригинальная имплементация превосходит остальные подходы.

4.2.3. Reacher Reach Hard




Рис. 6: Результаты обучения Reacher Reach Hard

Таблица 3: Численные данные по окружению Reacher Reach Hard

Reacher Reach Hard Environment			
methods \ backgrounds	Original	Video	Noise
DreamerV3	696.4 ± 58.0	9.9 ± 4.0	32.2 ± 19.0
Bisimulation (normal)	901.9 ± 17.0	8.3 ± 3.0	13.0 ± 4.0
Bisimulation (categorical)	363.0 ± 56.0	8.4 ± 4.0	15.1 ± 3.0
Ours	801.8 ± 30.0	16.2 ± 3.0	12.7 ± 5.0

В случае с оригинальным окружением снова лучше всего себя ведет функция потерь на основе бисимуляции (2). Модифицированная бисимуляция с включением действий (4) почти сходится к оригинальной бисимуляции. Адаптация бисимуляции к категориальному распределению в данной задаче и на данном окружении оказалась хуже всего.

В зашумленном видео окружении и в окружении со случайным шумом всем агентам не удалось обучиться приемлемой политике. Но в зашумлении видео выигрывает бисимуляция с включением действий, а в окружении со случайным шумом – оригинальная имплементация DreamerV3.

4.3. Выводы и результаты по главе

В данной главе было приведено описание окружений для экспериментов и описание технических моментов, связанных с экспериментами и построением графиков на основе их результатов.

Также были приведены результаты по каждому окружению с различными вариантами его зашумления, построены графики и приведены численные значения.

Следующая глава является завершающей, она содержит подведение итогов и перспективы дальнейшей деятельности.

ЗАКЛЮЧЕНИЕ

Целью данной работы была разработка функции потерь, учитывающей информацию о задаче, с целью получения информативных представлений в модельно-ориентированном обучении с подкреплением. Основой для разработки функции потерь являлась функция потерь на основе бисимуляции.

Поставленная цель была достигнута. В результате проделанной работы были выполнены следующие задачи:

1. были созданы различные варианты зашумленных окружений
 - было создано зашумление окружения с помощью случайного шума
 - было создано зашумление окружения с помощью коррелированного шума в виде последовательности кадров видео
2. метрика бисимуляции была адаптирована для использования ее с категориальным распределением;
 - функция расстояния между категориальными распределениями была выбрана с учетом теоретических оснований метрики бисимуляции
3. метрика бисимуляции была модифицирована путём включений в нее информации о действии
 - была предложена функция потерь на основе бисимуляции с использованием вероятностной модели динамики
 - была предложена функция потерь на основе бисимуляции без использования вероятностной модели динамики
4. проведено тестирование для оценки качества новых метрик и сравнение ее с существующими подходами.

Ниже приведена таблица результатов по предложенным подходам. В экспериментах участвовало 9 различных окружений (3 разных окружения по типу игры + 3 разных варианта зашумления).

Количество побед в 9 окружениях			
	Original	Video	Noise
Bisimulation (categorical)	1	1	0
Bisimulation (with actions) (4)	0	2	0
Total wins by approach	1	3	0

Таблица 4: Общие результаты по экспериментам

Удалось победить суммарно в 4 окружениях из 9, причем предложенный подход показывает свое преимущество в случае зашумления коррелированным шумом. Во многих других случаях предложенные подходы показали результаты не сильно хуже остальных.

Как можно заметить по результатам экспериментов, то в каких-то случаях оказывается лучше подход (2) – бисимуляции с использованием нормального распределения. В окружении Walker Walk (задача, связанная с передвижением) бисимуляция с включением действий превзошла остальные подходы на зашумленном видео окружении. В окружении Reacher Reach Easy (задача, связанная с точным контролем) лучше оказалась адаптированная к категориальному распределению бисимуляция. Поэтому дальнейшая работа может быть следующей: провести больше экспериментов на разных окружениях связанных с передвижением и точным контролем, выяснить есть ли тенденция, что какая-то функция потерь будет вести себя лучше в каком-то определенном типе задач. Также можно попробовать проверить какими полезными свойствами для обучения информативных представлений обладает расстояние Васерштейна по сравнению с дивергенцией Йенсена-Шеннона, или преимущество подхода (2) заключается в том, что гауссовское представление выхода модели динамики оказывается в каких-то ситуациях более полезным. Также необходимо проверить подход бисимуляции с включением действий с использованием вероятностной модели динамики.

СПИСОК ЛИТЕРАТУРЫ

Монографии

Sutton, R. S. & Barto, A. G. (2018). *Reinforcement learning: An introduction*. MIT press.

Периодические издания

Bengio, Y., Léonard, N. & Courville, A. (2013). Estimating or propagating gradients through stochastic neurons for conditional computation. *arXiv preprint arXiv:1308.3432*.

Briët, J. & Harremoës, P. (2009). Properties of classical and quantum Jensen-Shannon divergence. *Physical review A*, 79(5), 052311.

Castro, P. S. (2020). Scalable methods for computing state similarity in deterministic markov decision processes. *Proceedings of the AAAI Conference on Artificial Intelligence*, 34(06), 10069—10076.

Chen, T., Kornblith, S., Norouzi, M. & Hinton, G. (2020). A simple framework for contrastive learning of visual representations, 1597—1607.

Chopra, S., Hadsell, R. & LeCun, Y. (2005). Learning a similarity metric discriminatively, with application to face verification. *2005 IEEE computer society conference on computer vision and pattern recognition (CVPR'05)*, 1, 539—546.

Deng, F., Jang, I. & Ahn, S. (2022). Dreamerpro: Reconstruction-free model-based reinforcement learning with prototypical representations, 4956—4975.

Du, S., Krishnamurthy, A., Jiang, N., Agarwal, A., Dudik, M. & Langford, J. (2019). Provably efficient rl with rich observations via latent state decoding. *International Conference on Machine Learning*, 1665—1674.

Ferns, N., Panangaden, P. & Precup, D. (2011). Bisimulation metrics for continuous Markov decision processes. *SIAM Journal on Computing*, 40(6), 1662—1714.

Ferns, N. & Precup, D. (2014). Bisimulation Metrics are Optimal Value Functions. *UAI*, 210—219.

García, J., Visús, Á. & Fernández, F. (2022). A taxonomy for similarity metrics between Markov decision processes. *Machine Learning*, 111(11), 4217—4247.

Hafner, D., Lillicrap, T., Fischer, I., Villegas, R., Ha, D., Lee, H. & Davidson, J. (2019). Learning latent dynamics for planning from pixels, 2555—2565.

Hafner, D., Lillicrap, T., Norouzi, M. & Ba, J. (2020). Mastering atari with discrete world models. *arXiv preprint arXiv:2010.02193*.

Hafner, D., Pasukonis, J., Ba, J. & Lillicrap, T. (2023). Mastering diverse domains through world models. *arXiv preprint arXiv:2301.04104*.

- Kay, W., Carreira, J., Simonyan, K., Zhang, B., Hillier, C., Vijayanarasimhan, S., Viola, F., Green, T., Back, T., Natsev, P. и др. (2017). The kinetics human action video dataset. *arXiv preprint arXiv:1705.06950*.
- Lange, S., Riedmiller, M. & Voigtländer, A. (2012). Autonomous reinforcement learning on raw visual input data in a real world application, 1–8.
- Lee, A. X., Nagabandi, A., Abbeel, P. & Levine, S. (2020). Stochastic latent actor-critic: Deep reinforcement learning with a latent variable model. *Advances in Neural Information Processing Systems*, 33, 741–752.
- Okada, M. & Taniguchi, T. (2022). DreamingV2: Reinforcement learning with discrete world models without reconstruction, 985–991.
- Pathak, D., Agrawal, P., Efros, A. A. & Darrell, T. (2017). Curiosity-driven exploration by self-supervised prediction. *International conference on machine learning*, 2778–2787.
- Taylor, J., Precup, D. & Panagaden, P. (2008). Bounding performance loss in approximate MDP homomorphisms. *Advances in Neural Information Processing Systems*, 21.
- Tunyasuvunakool, S., Muldal, A., Doron, Y., Liu, S., Bohez, S., Merel, J., Erez, T., Lillicrap, T., Heess, N. & Tassa, Y. (2020). dm_control: Software and tasks for continuous control. *Software Impacts*, 6, 100022.
- Wahlström, N., Schön, T. B. & Deisenroth, M. P. (2015). From pixels to torques: Policy learning with deep dynamical models. *arXiv preprint arXiv:1502.02251*.
- Zhang, A., McAllister, R., Calandra, R., Gal, Y. & Levine, S. (2020). Learning invariant representations for reinforcement learning without reconstruction. *arXiv preprint arXiv:2006.10742*.